

基于迁移学习和深度卷积神经网络的乳腺肿瘤诊断系统

褚晶辉*, 吴泽蕊, 吕卫**, 李喆

天津大学电气自动化与信息工程学院, 天津 300072

摘要 乳腺肿瘤计算机辅助诊断(CAD)系统在医学检测和诊断中的应用日益重要。为了区分核磁共振图像(MRI)中肿瘤与非肿瘤,利用深度学习和迁移学习方法,设计了一种新型乳腺肿瘤 CAD 系统:1)对数据集进行不平衡处理和数据增强;2)在 MRI 数据集上,利用卷积神经网络(CNN)提取 CNN 特征,并利用相同的支持向量机分类器,计算每层 CNN 的特征图的分类 F1 分数,选取分类性能最高的一层作为微调节点,其后维度较低层为连接新网络节点;3)在选取的网络接入节点,连接新设计的两层全连接层组成新的网络,利用迁移学习,对新网络载入权重;4)采用固定微调节点前的网络层不可训练,其余层可训练的方式微调。分别基于深度卷积网络(VGG16)、Inception V3、深度残差网络(ResNet50)构建的 CAD 系统,性能均高于主流的 CAD 系统,其中基于 VGG16 和 ResNet50 搭建的系统性能突出,且二次迁移可以提高 VGG16 系统性能。

关键词 图像处理; 乳腺肿瘤诊断; 图像分类; 深度卷积神经网络; 计算机辅助诊断系统; 迁移学习

中图分类号 TN919.8

文献标识码 A

doi: 10.3788/LOP55.081001

Breast Cancer Diagnosis System Based on Transfer Learning and Deep Convolutional Neural Networks

Chu Jinghui*, Wu Zerui, Lü Wei**, Li Zhe

School of Electronic Information Engineering, Tianjin University, Tianjin 300072, China

Abstract Breast cancer computer-aided diagnosis (CAD) system is playing more and more important role in medical detection and diagnosis. In order to classify tumor and non-tumor in magnetic resonance imaging (MRI), a novel breast cancer CAD system based on deep learning and transfer learning is designed. First, we balance the imbalanced data sets and use data augmentation to deal with it. Then, we use the convolutional neural network (CNN) to extract CNN features from MRI data sets, use the same support vector machine to evaluate the feature extraction abilities of different layers, and select the highest F1 score layer as the node of fine-tuning, the layers behind it, which has relatively low dimension as the node of connection of new networks. Next, we select the newly designed fully-connected layers with two layers to form a new network, and use transfer learning to load weights on the new network. At last, we freeze the layers before the node of fine-tuning, while other layers can be trained in the fine-tuning procedure. The CAD systems are built on three CNN networks, including VGG16, Inception V3, and ResNet50. The effects of the system based on VGG16 and ResNet50 have the best performance, and twice transfer learning can improve the performance of VGG16 network system.

Key words image processing; breast tumor diagnosis; image classification; deep convolutional neural networks; computer-aided diagnostic system; transfer learning

OCIS codes 100.2000; 110.3000; 080.1235

1 引言

乳腺癌具有高致病性,逐渐成为女性患病致死的一个主要因素^[1]。在医学研究中,鲜有研究者针

对乳腺肿瘤发病机制提出有效的治愈方法。采取医学影像拍摄检查对肿瘤进行早期诊断,有助于降低乳腺癌患者的死亡率^[2]。然而,查看大量乳腺影像图像易使医师疲劳,并且诊断准确性还受限于医师

收稿日期: 2017-10-13; 修回日期: 2017-11-08; 录用日期: 2017-11-23

基金项目: 国家自然科学基金(61271069)

* E-mail: cjh@tju.edu.cn; ** E-mail: luwei@tju.edu.cn

081001-1

的经验和职业能力等。乳腺肿瘤计算机辅助诊断(CAD)系统在辅助医师提升诊断结果的精度和灵敏度方面发挥了重要作用^[3]。目前,主要通过传统机器学习方法搭建CAD系统,但所搭建系统性能的提升遇到瓶颈^[4-6]。

针对以上问题,本文结合深度学习与迁移学习方法^[5,7],提出新型乳腺肿瘤诊断系统:1)选用正样本数目远小于负样本数目的不平衡数据集——乳腺X光数字乳腺图像数据库(DDSM)肿瘤数据集和乳腺核磁共振图像(MRI)肿瘤数据集,对数据集的正样本进行随机升采样,使得数据集均成为平衡数据集^[8];2)对平衡之后的数据集进行数据增强处理^[9],使数据集的数据量得到了小幅度扩增,同时降低深度学习中模型过拟合的可能性;3)在深度学习的基础上引入迁移学习,源域为ImageNet中自然图像,目标域为MRI数据集,利用除去全连接层之后的剩余卷积神经网络(CNN)各层,分别在MRI数据集上提取特征。采用相同的支持向量机(SVM)^[6]分类器进行分类,选取提取CNN特征^[10-12]F1分数最高的层记为L1,作为后期新网络微调的节点,选取L1层后面维度最低的层记为L2作为接入新层的节点;接入L3、L4全连接层之后,引入迁移学习,采用L1层前所有层参数固定不可训练的方式,在MRI数据集上微调。

在此基础上,提出了二次迁移的方法。由于ImageNet自然图像与MRI乳腺肿瘤图像存在较大差距,迁移的效果仍存在提升空间^[13],通过二次迁移的方法引入DDSM医学图像数据集加入到训练的过程:1)将在ImageNet与医学影像DDSM之间进行迁移学习;2)在此基础上进行持续的迁移,MRI数据集作为第二次迁移的目标域。结果表明,二次迁移方法可有效提高系统的性能。

2 系统设计原理

2.1 不平衡数据处理和数据增强处理

数据不平衡^[8]现象在医学领域图像数据集中普遍存在。本文所采用数据集的数据不平衡形式主要为类间不平衡。数据的不平衡会导致算法和网络在学习过程中更关注多数类别样本,而少数类别样本相对被忽视。然而,在医学图像中,与多数类别样本相比,少数类别样本包含的信息通常更重要。选取少数类别样本为数据集的正样本,将其错分呈现更高的代价。因此,利用随机升采样的算法进行不平衡处理。随机升采样算法的优势在于:不会移除少

数类别样本集中信息,保证少数类别样本集中信息损失为零。在经典的CNN AlexNet^[5]中引入数据增强方法,可以降低参数量大的CNN过拟合的可能性,提高泛化能力。通过增加图片的副本,使网络可以学到更多图像不变性特征;在训练数据中增加冗余信息,提高数据的利用率和网络的泛化能力;针对平衡之后的数据,采取数据增强处理,并进行旋转变换、翻转变换和平移变换。

2.2 CNN特征和传统机器学习特征

将深度卷积网络(VGG16)^[14]、Inception V3^[15]、深度残差网络(ResNet50)^[16]等在ImageNet中表现优异的CNN作为系统改进与搭建的基础。特征的优劣在最终的分类结果中起到关键性作用。为了验证深度学习方法优于传统机器学习方法,在特征层面,证明CNN层提取的特征优于传统机器学习方法提取的特征性能。分别在MRI数据集上提取CNN特征^[7]和传统机器学习特征。利用提取的特征训练相同的SVM分类器,进行分类性能比较。此外,分别探究三个不同CNN的网络层内部,在MRI数据集上提取特征性能的差异^[15],以此来指导新网络的搭建方式和迁移学习的引入方式。

2.3 迁移学习、二次迁移与数据联合训练

迁移学习中,以小数据量的样本集作为目标域,以大量标注的数据集作为源域^[7]。主要有两大类:1)目标域与源域图像差别较小时,通过两个数据集间数学映射关系,扩充目标域的数据量;2)目标域与源域图像差别较大时,建立在卷积神经网络层、特征层之间的迁移。第二类迁移学习方式适用于本文的小数据集医学图像,利用自然图像数据集ImageNet和深度CNN进行迁移学习^[11-12,17]。在迁移学习过程中,主流观点认为,相近的种类迁移效果优于两个相差较大类之间的迁移。ImageNet自然图像与医学肿瘤图像之间有较大差距,但医学影像领域不存在大规模数据集。基于以上条件,本文提出二次迁移方法,将加入乳腺X光数据集作为第一次迁移的目标域,第二次迁移的目标域为MRI数据集。此外,还进行了联合数据训练,两个不同医学影像数据集均为乳腺肿瘤数据集,存在一定相似性。由于目标数据集数据量过小,本文将两个数据集联合起来,作为一个整体数据集进行训练^[18-19]。

3 系统设计流程

系统设计主要由两部分组成。1)构建新CNN,分别对VGG16、Inception V3、ResNet50的不同层,

在 MRI 数据集上提取特征,比较层内提取的特征在相同 SVM 分类效果上的差异,标记分类性能最高的层,并将其后较低维度的层与新设计的两层全连接层连接,形成新网络。2)在搭建的新 CNN 网络结构基础上,加入迁移学习与二次迁移学习^[12]。将在 ImageNet 预训练的权重迁移至新网络结构的对应部分,通过在数据集上预训练获得剩余新设计的网络层权重;在 MRI 数据集上微调时,网络特定层参数不可训练,其余层训练中可变。

3.1 新 CNN 的搭建

3.1.1 传统特征与 CNN 特征

选取 Gabor^[20]、灰度共生矩阵 (GLCM)^[21] 和 Harrlike^[22] 等普遍应用于医学图像中的传统机器学习特征,在 VGG16 相同数据集上,分别提取传统机器学习特征和 CNN 特征。之后,利用 Inception V3 和 ResNet50 分别提取 CNN 层内特征,并比较提取

的特征在相同 SVM 分类效果上的差异。如图 1(a)所示,依次进行以下比较实验:1)在 MRI 数据集上提取三种传统机器学习特征:Gabor、GLCM 和 Harrlike 特征;2)除去 VGG16 网络最后三层全连接层,在 VGG16 网络其他不同层的 MRI 数据集上提取特征^[5],图 1(b)为 VGG16 层结构,L1、L2 为两个指针,由分类性能结果决定其位置;3)将独立提取的三种传统机器学习特征进行特征融合,即将三种机器学习特征串联;4)将 CNN 中特定层提取的特征分别与三个传统机器学习特征进行结合,将三种机器学习方法扁平化为一维,加入 CNN 中扁平化之后的层来检验传统特征的加入是否有助于增强深度学习特征的表达能力;5)针对 Inception V3 和 ResNet50 网络结构,在不同的块中,分别选取少数网络层,在 MRI 上进行特征提取^[5]。选取的少数层性能,可代表临近层在 MRI 上的特征提取性能。

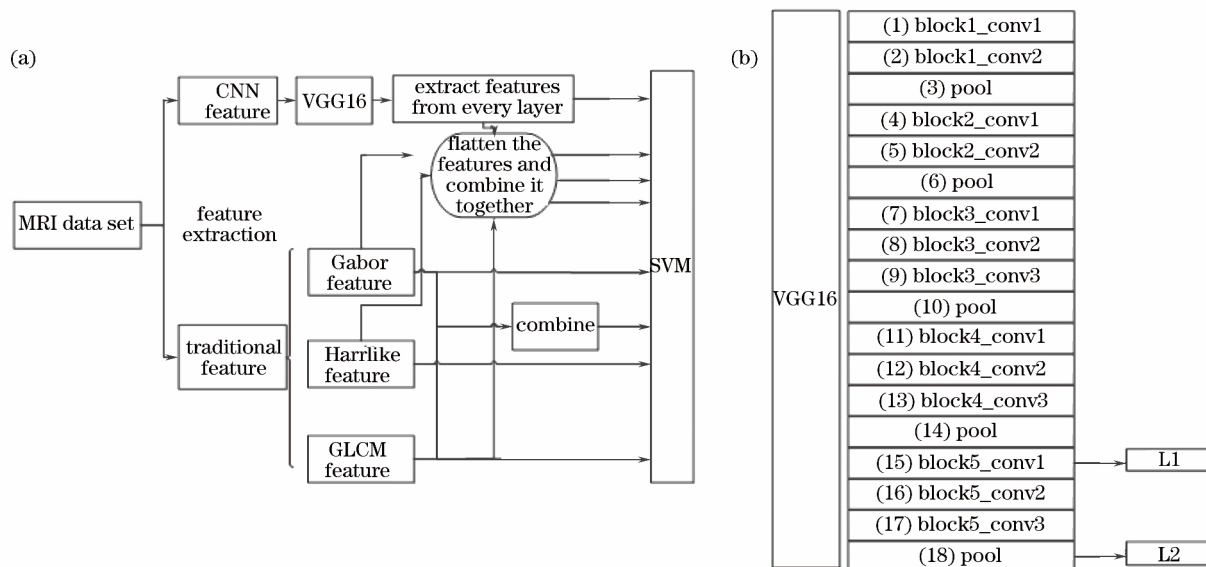


图 1 (a)传统特征与 CNN 特征提取过程的比较;(b) VGG16 层结构展示

Fig. 1 (a) Comparison of extraction between traditional machine learning features and CNN features;

(b) illustration of the layers of VGG16

3.1.2 新网络的构建

全连接层在原本 CNN 中占据最大参数量,较大的参数量易造成过拟合,且根据本文的分类任务,去除网络中原本的全连接层。设计两个全连接层作为新接入的网络层,流程如图 2(a)所示。根据 3.1.1 节中的特征探究方法得到的分类结果,选取 F1 分数最高的层记为 L1,作为微调的节点,并在 L1 层之后的层中选取维度较低的层为 L2,作为网络接入节点。选取 L2 的原因是由于 L2 层与 L3 全连接层相接,会产生较大的参数量。在 L2 基础上,接新的两层全连接层 L3、L4,形成新的 CNN。L3、L4 两个全连接层

分别设置为 256 和 1,且在 L3 层之后加入随机断开层,其值设置为 0.5。

3.2 迁移学习与二次迁移学习的引入

针对 VGG16,将其在 ImageNet 上进行预训练的权重迁移至新网络对应部分,即图 1(b)中 L2 层之前的网络部分。使用 3.1.1 节中 CNN 提取出的特征,在新设计的网络层上进行训练,即 L3、L4 层。训练性能达到最佳时,停止训练,保存 L3、L4 网络层权值,并载入到新网络的对应部分。网络在 MRI 数据集上微调时,采用方式 C,并以方式 A、B 作为对比实验,如图 2(a)所示。其中方式 A 为新的

CNN,不引入迁移学习,网络所有参数随机初始化进行训练;方式B为将新网络的所有层初始化之后,网络的所有层参数可训练;方式C为新网络的所有层初始化之后,1-L1层参数固定不变,剩余层L2~L4参数可训练。图2(b)为二次迁移方法流程。第一步:目标域为 DDSM 数据集,ImageNet 作为源域。根据 3.2 节方法搭建新网络,即将在

ImageNet 预训练之后的权重,迁移到网络 L2 层之前的所有层;在 DDSM 数据集上,选用方式 C 进行网络权重迁移和微调。第二步:目标域为 MRI 数据集。第二次迁移是建立在第一次迁移之后的网络基础上,将第一次训练得到的最好模型权重进行迁移,再将经过不平衡处理、数据增强之后的 MRI 数据集,按照方式 C 进行网络微调。

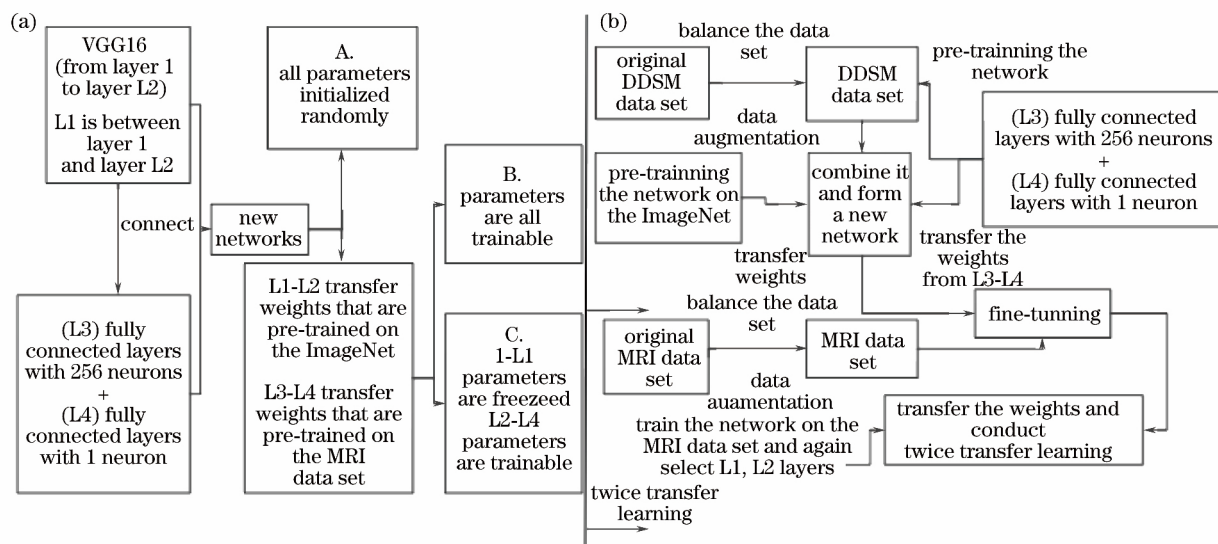


图 2 (a)新网络的构建流程以及迁移方式;(b)二次迁移方法流程

Fig. 2 (a) Flow of network construction and the way of transfer learning; (b) flow of two-step transfer learning method

4 系统优异性验证与实验结果

4.1 DDSM 数据集与 MRI 数据集概述

DDSM 数据集^[16]为公开的乳腺 X 光数据集。通过提供的掩模,提取出原图像中感兴趣区域,共包含 402 个正样本和 1565 个负样本。经不平衡处理与数据增强之后的数据集中 70% 的样本作为训练集,30% 的样本作为测试集。数据集中良性肿瘤与恶性肿瘤为正样本,非肿瘤样本为负样本,图 3 为部

分样本。所选 MRI 乳腺癌数据集为 DICOM 格式的图像,数据来源于山东省肿瘤医院,采集自飞利浦 3 TMR 系统,分辨率为 360 dpi。数据中包含 54 名患者,年龄范围为 35~60 岁。经手动分割得到感兴趣区域,注释并标记,最终经过放射科医师鉴定有效。图 4 为被标记的感兴趣区域图像,包含 538 个正样本和 2313 个负样本。处理之后的数据集中 70% 的样本作为训练集,20% 的样本作为验证集,10% 的样本作为测试集。




图 3 DDSM 图像中的感兴趣区域。(a)~(c)正样本;(d)~(f)负样本

Fig. 3 Regions of interesting of DDSM data sets. (a)~(c) Positive examples; (d)~(f) negative examples

4.2 系统设计实验结果

所有实验均在一台配备了 NVIDIA 制造的 Tesla K80 GPU 服务器上进行,利用高度模块化的

深度学习库 Keras 实现,调用 Theano 做支持,选取 SGD 为迁移学习的优化函数,学习率设置为 0.0001,动量设置为 0.9。




图 4 MRI 图像中标注的感兴趣区域。(a)~(c)为正样本;(d)~(f)为负样本

Fig. 4 Reference images of MRI region of interest. (a)~(c) Positive examples; (d)~(f) negative examples

4.2.1 CNN 特征性能探究与优异性验证

表 1 为 3.1 节特征提取的结果,同类最优结果标记为黑体。Gabor、GLCM、HarrLik 特征的融合记为 Combination。VGG16 提取得到的 CNN 特征如表 2 所示。表 1 中以 VGG16 第 16 层特征(VGG16-16L)做 CNN 特征代表,CNN 层特征分别与 3 种传统机器学习方法相结合的特征分别简写为 V-HarrLike, V-Gabor, V-GLCM。从 CNN 中提取的特征即 VGG16-16L,F1 参数上表现明显优于传统的机器学习特征。3 种传统机器学习方法特征分别与 CNN 特征融合,提升了 F1 分数,使传统特

征的表达性能接近 CNN 本身的特征性能。结果表明,CNN 特征优于传统机器学习特征^[23-25]。如表 2 所示,VGG16 网络层内 8~17 层包含不同的池化层、卷积层,在 MRI 上提取特征的性能差异,其中 14 层 F1 参数最高。结果显示,在 CNN 网络内部,随着网络层的加深,网络层提取的特征,对于最终的分类任务,其性能呈现上升趋势。研究表明^[17-19],CNN 的更深层所提取的特征更加高层、抽象,而相对较浅网络层提取的特征则包含更多的图像边缘轮廓、纹理等底层信息。将 L1 设置在 14 层的位置,其后的 18 层特征维度较低,将 L2 设置在此位置。

表 1 特征性能比较

Table 1 Comparison of feature performance

Performance metric	Gabor	GLCM	HarrLike	Combination	V-HarrLike	V-Gabor	V-GLCM	VGG16-16L
Accuracy	0.8702	0.8844	0.7302	0.8299	0.9074	0.8784	0.8734	0.9042
Precision	0.9193	0.8681	0.7117	0.8222	0.8737	0.8784	0.8734	0.8924
Recall	0.8117	0.9066	0.7737	0.8417	0.9025	0.9145	0.9177	0.9193
F1	0.8621	0.8869	0.7737	0.8318	0.9114	0.8961	0.8950	0.9056

表 2 VGG16 层内提取特征性能比较

Table 2 Performance comparison of extracted features in VGG16 layers

Performance metric	Layer 8	Layer 9	Layer 10	Layer 11	Layer 12	Layer 13	Layer 14	Layer 15	Layer 16	Layer 17
Accuracy	0.6724	0.6094	0.6028	0.7998	0.9074	0.9185	0.9319	0.9303	0.9042	0.8678
Precision	0.6116	0.5632	0.5596	0.7269	0.8737	0.9025	0.9099	0.9121	0.8924	0.8571
Recall	0.9446	0.9642	0.9651	0.9604	0.9525	0.9382	0.9588	0.9525	0.9193	0.8829
F1	0.7425	0.7110	0.7084	0.8275	0.9114	0.9200	0.9337	0.9318	0.9056	0.8698

4.2.2 系统加入迁移学习的优异性验证

图 5 所示为加入迁移学习与不加入迁移学习的三个系统在 F1 分数上的对比。结果显示,加入迁移学习方式的网络性能更优,其中基于 VGG16 与 ResNet50 搭建的系统性能优于 Inception V3。如表 3 所示,引入迁移学习的网络,在微调阶段采用 B、C 两种不同的微调方式,其中方式 C(L1 之前的网络层权重保证不变,剩余层网络权重可训练的方式)比方式 B(网络全部权重均可训练的方式)得到的网络性能更佳。结果表明,对于小数据集应用较深层网络,加入迁移学习,有助于提升系统最终的性能;在采用小数据集微调时,采用方式 C(固定

特定层权重不可变,其余层参数改变的方式)可提升网络性能,使分类结果更优。

4.2.3 二次迁移与联合数据训练优异性验证

表 3 为二次迁移学习与一次迁移、数据联合训练,及基于 VGG16 搭建的系统性能差异。结果表明,针对医学小数据集,二次迁移能够明显提升系统性能,在可获得类别近似数据集情况下,数据联合训练也可以取得较好的效果,并且接近二次迁移的实验结果;数据的联合训练、二次迁移方式有效,均可以在引入迁移学习的基础上进一步提升系统性能,为小数据集和医学影像数据集的分类任务提供参考依据。

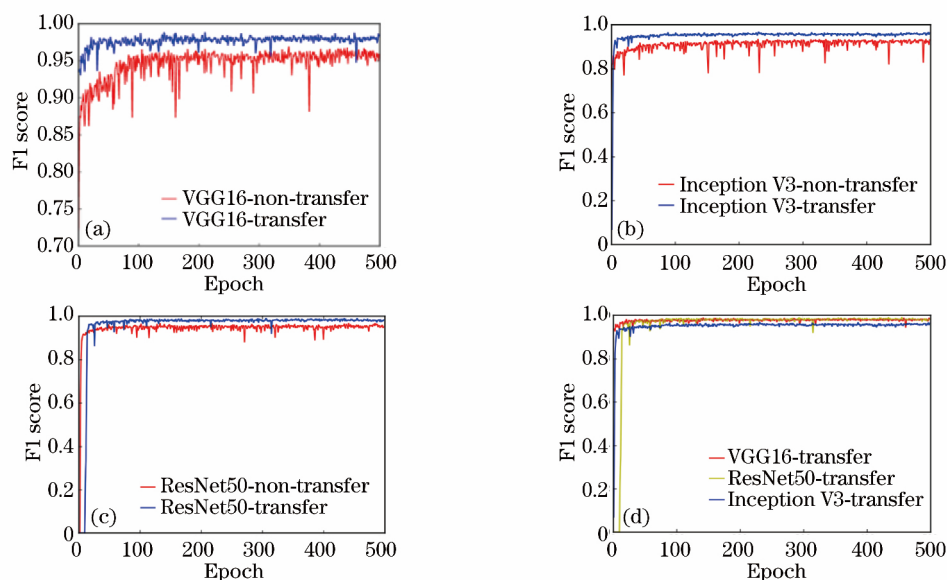


图 5 基于(a) VGG16、(b) Inception V3 和(c) ResNet50 搭建系统迁移学习和不迁移学习性能；
(d)基于迁移学习的三个系统性能对比

Fig. 5 Transfer learning and non-transfer learning of the system based on (a) VGG16, (b) Inception V3 and (c) ResNet50;
(d) performance comparison of the three systems based on transfer learning

表 3 不同方法性能比较

Table 3 Comparison of evaluation index obtained by different methods

Method	F1 score	Precision	Recall	Accuracy	AUC
Twice transfer learning based on VGG16	0.9742	0.9687	0.9798	0.9795	0.9749
Combine the data sets together based on VGG16	0.9722	0.9667	0.9778	0.9790	0.9732
Once transfer learning based on VGG16	0.9620	0.9668	0.9574	0.9706	0.9682
Fine-tuning with method B based on VGG16	0.9590	0.9627	0.9554	0.9668	0.9650
Fine-tuning with method C based on VGG16	0.9620	0.9668	0.9574	0.9706	0.9682
Fine-tuning with method B based on ResNet50	0.9642	0.9596	0.9687	0.9685	0.9685
Fine-tuning with method C based on ResNet50	0.9680	0.9723	0.9638	0.9732	0.9710

5 结 论

为了进一步提升乳腺肿瘤 CAD 系统的性能,在深度学习的基础上引入迁移学习,并提出二次迁移学习,提升了分类性能,缓解了医学数据集引入深度学习困难的问题。为了验证该系统的优异性,分别与传统机器学习方法、未引入迁移学习的方法、数据联合训练的方法进行对照实验。结果表明,特定的迁移学习方式可以提升网络分类性能,在可获得相似数据集的情况下,数据联合训练可以提升分类性能,二次迁移方法更加有效,为较优选择;迁移学习的特定引入方式、二次迁移学习、数据联合训练的方法均可为小数据集、医学影像数据集的分类任务提供参考依据。

参 考 文 献

[1] Pei C D, Wang C M, Xu S Z. Segmentation of the

breast region in mammograms using marker-controlled watershed transform[C]. The 2nd IEEE International Conference on Information Science and Engineering, 2010; 2371-2374.

- [2] Ries L A G, Harkins D, Krapcho M, *et al.* SEER cancer statistics review, 1975-2003[R]. Bethesda: National Cancer Institute, 2006.
- [3] Fenton J J, Taplin S H, Carney P A, *et al.* Influence of computer-aided detection on performance of screening mammography[J]. New England Journal of Medicine, 2007, 356(14): 1399-1409.
- [4] Tang J, Rangayyan R M, Xu J, *et al.* Computer-aided detection and diagnosis of breast cancer with mammography: recent advances [J]. IEEE Transactions on Information Technology in Biomedicine, 2009, 13(2): 236-251.
- [5] Litjens G, Kooi T, Bejnordi B E, *et al.* A survey on deep learning in medical image analysis[J]. Medical

- Image Analysis, 2017, 42: 60-88.
- [6] Yoon S, Kim S. Mutual information-based SVM-RFE for diagnostic classification of digitized mammograms [J]. Pattern Recognition Letters, 2009, 30(16): 1489-1495.
- [7] Pan S J, Yang Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359.
- [8] Japkowicz N. Learning from imbalanced data sets; a comparison of various strategies [C]. AAAI Workshop on Learning from Imbalanced Data Sets, 2000, 68: 10-15.
- [9] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks [J]. Advances in Neural Information Processing Systems, 2012: 1097-1105.
- [10] Sharif R A, Azizpour H, Sullivan J, *et al.* CNN features off-the-shelf: an astounding baseline for recognition [C]. IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2014: 806-813.
- [11] Boureau Y L, Bach F, LeCun Y, *et al.* Learning mid-level features for recognition [C]. IEEE Conference on Computer Vision and Pattern Recognition, 2010: 2559-2566.
- [12] Le Q V. Building high-level features using large scale unsupervised learning [C]. IEEE International Conference on Acoustics, Speech and Signal Processing, 2013: 8595-8598.
- [13] Bar Y, Diamant I, Wolf L, *et al.* Chest pathology detection using deep learning with non-medical training[J]. IEEE 12th International Symposium on Biomedical Imaging, 2015: 294-297.
- [14] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [C]. International Conference on Learning Representations, 2015.
- [15] Szegedy C, Vanhoucke V, Ioffe S, *et al.* Rethinking the inception architecture for computer vision [C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2818-2826.
- [16] He K, Zhang X, Ren S, *et al.* Deep residual learning for image recognition [C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [17] Khan S A, Yong S P. An evaluation of convolutional neural nets for medical image anatomy classification [J]. Advances in Machine Learning and Signal Processing, 2016: 293-303.
- [18] Liu D W, Han L, Han X Y. High spatial resolution remote sensing image classification based on deep learning[J]. Acta Optica Sinica, 2016, 36(4): 0428001.
刘大伟, 韩玲, 韩晓勇. 基于深度学习的高分辨率遥感影像分类研究[J]. 光学学报, 2016, 36(4): 0428001.
- [19] Cheng X J, Guo W, Li Q, *et al.* Joint classification method for terrestrial LiDAR point cloud based on intensity and color information[J]. Chinese Journal of Lasers, 2017, 44(10): 1010007.
程效军, 郭王, 李泉, 等. 基于强度与颜色信息的地面 LiDAR 点云联合分类方法[J]. 中国激光, 2017, 44(10): 1010007.
- [20] Kitanovski I, Jankulovski B, Dimitrovski I, *et al.* Comparison of feature extraction algorithms for mammography images [C]. The 4th International Congress on Image and Signal Processing, 2011: 888-892.
- [21] Hong J. Gray level-gradient cooccurrence matrix texture analysis method[J]. Acta Automatica Sinica, 1984, 10(1): 22-25.
- [22] Galloway M M. Texture analysis using gray level run lengths [J]. Computer Graphics and Image Processing, 1975, 4(2): 172-179.